

Rota

Dataset: Da Alemanha - Cintia está fazendo a parte das anotações nas imagens

- Thiago sugeriu usar o 3d slicer!
- Pré processamento:
 - acredito que o dataset é bom, mas precisamos tanto treinar com as imagens inteiras quanto com as imagens recortadas das células
 - Balancear as classes: `Parasitized` (label 0) e `Uninfected` (label 1).
 - Redimensionar para 224×224 (padrão para os modelos).
 - Normalização de pixel `[0, 1]` ou `[-1, 1]` conforme o modelo.

Usar 4 modelos para a classificação:

- Swin Transformer
 - Transformer hierárquico com atenção por janelas
 - Considera contexto local e global.
 - Pode capturar padrões estruturais de forma diferente de CNNs.
 - Ideal para análises de explicabilidade com atenção.
- ResNet50
 - CNN profunda com conexões residuais.
 - Forte em tarefas médicas.
 - Ótimo para Grad-CAM.
 - MUITO USADA PRA MALÁRIA (tem muitos artigos)
- EfficientNetB0 ou B4
 - CNN escalonável com excelente relação desempenho/eficiência.
 - Menor quantidade de parâmetros.
 - Excelente acurácia mesmo em versões pequenas.
 - Escala bem (B0 para rápido, B4 para mais robusto).

- DenseNet121
 - CNN com conexões densas entre camadas.
 - Propagação eficiente de gradientes.
 - Gera representações muito detalhadas das imagens.
 - Muito usado em aplicações médicas (ex: radiologia).

Modelo	Origem	Onde importar
ResNet50	CNN	<code>torchvision.models.resnet50</code>
DenseNet121	CNN com conexões densas	<code>torchvision.models.densenet121</code>
EfficientNetB0	CNN otimizado	<code>torchvision.models.efficientnet_b0</code>
Swin Transformer	Vision Transformer	<code>transformers</code> (Hugging Face)

Explicabilidade:

- ResNet, DenseNet, EfficientNet: Grad-CAM.
- Swin Transformer: Atenção via rollout ou visualização direta dos heads.

Nesses casos aqui podemos usar também a unet como mais uma comparação de explicabilidade

Modelo	Classifica?	Explica via Grad-CAM?	Explica via U-Net?
ResNet50	✓ Sim	✓ Sim	✓ Sim
DenseNet121	✓ Sim	✓ Sim	✓ Sim
EfficientNetB0	✓ Sim	✓ Sim	✓ Sim
Swin Transformer	✓ Sim	◆ Parcial (atenção)	✓ Sim

- Treinar a U-Net para **segmentar regiões com parasitas** (com máscaras reais ou pseudo-máscaras como Grad-CAM/atenção).
- Depois, **rodar a U-Net em paralelo** com os classificadores para gerar o "mapa explicativo".
- Isso gera:

`classificação = positivo`

`explicação = máscara sobreposta na imagem`

[Imagem] → [Classificador: Swin / ResNet / etc] → Previsão

↓

[U-Net] → Máscara de explicação

Se quisermos fazer aquela explicabilidade em texto, podemos pensar em algo como: (ajuda do chat gpt nessa)

1. Salve outputs organizadamente

- Para cada imagem processada, salve:
 - A imagem original.
 - O label verdadeiro.
 - A predição do modelo.
 - O mapa de atenção (Grad-CAM, Rollout, U-Net).
 - Se a predição foi correta ou incorreta.

```
/resultados/  
malaria_001/  
- original.jpg  
- pred_label.txt (Ex: "Predito: malária — Real: malária — Correto )  
- gradcam.png  
- rollout.png  
- unet_mask.png
```

1. Criar um relatório por imagem

Aqui podemos gerar algumas mensagens automáticas, mas estou pensando em como podemos fazer de uma forma melhor (talvez usar o chat gpt ou outra rede para ajudar na construção dos textos)

```
def gerar_relato(nome_img, label_real, predicao, correto, explicacao_modelo):  
    status = "correta  " if correto else "incorreta   
    base = f"A imagem {nome_img} foi classificada como '{predicao}', sendo a  
  
    if explicacao_modelo == "gradcam":
```

```
    return base + " O mapa de Grad-CAM indica que o modelo focou em regi  
elif explicacao_modelo == "rollout":  
    return base + " A atenção acumulada mostra influência em regiões perifé  
elif explicacao_modelo == "unet":  
    return base + " A U-Net segmentou regiões compatíveis com a forma do
```